

MẠNG NƠ-RON CUỘN (CONVOLUTIONAL NEURAL NETWORKS - CNN)

Kiến thức Lý thuyết, Công thức Toán học & Kiến trúc Chi tiết (MIT 6.S191 Guide)

1. Tổng quan & Động lực của Mạng Nơ-ron Cuộn (CNN)

Trong Thị giác Máy tính (Computer Vision), dữ liệu đầu vào là các bức ảnh 2D hoặc 3D (Chiều cao H $\times$ Chiều rộng W $\times$ Số kênh màu C). Mạng Nơ-ron Truyền thống (Fully Connected / Dense Networks) gặp phải **3 hạn chế chí mạng** khi xử lý dữ liệu ảnh:

- Bùng nổ Số lượng Tham số (Parameter Explosion):** Với ảnh độ phân giải $1000 \times 1000 \times 3$, vector đầu vào có $3.000.000$ phần tử. Một lớp ẩn 1000 nơ-ron sẽ đòi hỏi tới **3 tỷ trọng số**, gây tràn bộ nhớ GPU và cực kỳ dễ bị Overfitting.
- Mất Cấu trúc Không gian (Loss of Spatial Structure):** Việc duỗi thẳng (flatten) ảnh 2D thành vector 1D làm phá hủy hoàn toàn mối tương quan không gian giữa các điểm ảnh lân cận (pixel lân cận chứa thông tin hình dạng quan trọng nhất).
- Thiếu tính Bất biến Dịch chuyển (Lack of Translation Invariance):** Mạng Fully Connected coi điểm ảnh ở góc trên-trái và góc dưới-phải là hai đặc trưng độc lập. Nếu con mèo di chuyển vị trí trong ảnh, mạng FC sẽ không thể nhận diện được nếu chưa được học ở vị trí mới.

Giải pháp của CNN: Sử dụng **Thụ thể Cục bộ (Local Receptive Fields)** và **Chia sẻ Trọng số (Parameter Sharing)**. Thay vì kết nối mọi điểm ảnh tới mọi nơ-ron, một bộ lọc (Filter/Kernel) kích thước nhỏ ($k \times k$) quét qua toàn bộ ảnh, dùng chung một bộ trọng số để trích xuất đặc trưng không gian.


2. Các Thành phần Cốt lõi & Công thức Toán học của CNN

Mạng CNN biến đổi dữ liệu ảnh thông qua phép toán **Cuộn (Convolution)**, hàm kích hoạt phi tuyến, và các lớp nén không gian (Pooling).

a) Phép toán Cuộn 2D (2D Convolution Operation)

Phép toán cuộn giữa Ma trận Ảnh đầu vào I và Bộ lọc Kernel K kích thước $(k_h \times k_w)$ tại vị trí tọa độ (i, j) được định nghĩa toán học như sau:

$$\text{Công thức Phép Cuộn 2D: } (I * K)(i, j) = \sum_m \sum_n I(i + m, j + n) \cdot K(m, n)$$



Hình 1: Minh họa Phép cuộn giữa Ảnh đầu vào (5x5) và Kernel (3x3) tạo ra Feature Map (3x3).

b) Công thức Kích thước Đầu ra (Output Feature Map Dimensions)

Cho Ảnh đầu vào kích thước $W \times H$, Kernel kích thước $K \times K$, độ rộng Padding P , và bước nhảy Stride S . Kích thước của Feature Map đầu ra $(W_{out} \times H_{out})$ được tính chính xác theo công thức:

Công thức Kích thước Feature Map:

$$W_{out} = \lfloor (W - K + 2P) / S \rfloor + 1 \quad H_{out} = \lfloor (H - K + 2P) / S \rfloor + 1$$


- **Padding (P):** Thêm các hàng/cột chứa giá trị 0 xung quanh viền ảnh. Valid Padding ($P=0$) làm giảm kích thước ảnh; Same Padding ($P = \frac{K-1}{2}$) giữ nguyên kích thước không gian ($W_{out} = W$).
- **Stride (S):** Số bước nhảy của Kernel khi trượt trên ảnh. Stride $S > 1$ giúp giảm kích thước không gian của Feature Map.
- **Số kênh Đầu ra (C_{out}):** Bằng đúng số lượng Bộ lọc (Filters) được áp dụng ở lớp cuộn đó.

3. Lớp Gộp (Pooling Layer) & Hàm Kích hoạt Phi tuyến

Sau phép cuộn, Feature Map được đưa qua hàm kích hoạt **ReLU** $f(x) = \max(0, x)$ để tạo tính phi tuyến, sau đó tiếp tục đi qua lớp **Pooling** để giảm chiều không gian (Downsampling).

Cơ chế Max Pooling & Average Pooling:


Lớp Pooling trượt một cửa sổ ($k \times k$) qua Feature Map và giữ lại thông tin đại diện. **Max Pooling** lấy giá trị lớn nhất trong cửa sổ, giúp giữ lại các đường nét/kích hoạt mạnh nhất và tạo tính bất biến dịch chuyển cục bộ. Lớp Pooling **không chứa bất kỳ tham số học (weights) nào**, giúp giảm 75% khối lượng tính toán khi dùng cửa sổ 2×2 với $S=2$.



Hình 2: Minh họa Max Pooling kích thước 2x2 với Stride 2 biến ma trận 4x4 thành 2x2.

4. Kiến trúc CNN Hoàn chỉnh & Học Đặc trưng Phân cấp

Một mô hình CNN hoàn chỉnh kết hợp chuỗi khối trích xuất đặc trưng `[Conv -> ReLU -> Pool]` với lớp phân loại Fully Connected ở cuối.



Hình 3: Sơ đồ luồng xử lý End-to-End trong Kiến trúc Mạng Nơ-ron Cuộn (CNN).

Quá trình Học Đặc trưng Phân cấp (Hierarchical Feature Learning):

- **Lớp Cuộn Đầu (Low-Level Features):** Học các đặc trưng thị giác cơ bản như đường cạnh (edges), góc (corners), dải màu sắc và gradient.
- **Lớp Cuộn Giữa (Mid-Level Features):** Kết hợp các đường cạnh để tạo thành kết cấu (textures), hoa văn, các bộ phận nhỏ (mắt, mũi, bánh xe).
- **Lớp Cuộn Sâu (High-Level Features):** Tổng hợp các bộ phận thành các đối tượng trừu tượng hoàn chỉnh (khuôn mặt, xe hơi, con chó).
- **Lớp Phân loại (Fully Connected & Softmax):** Duỗi (Flatten) ma trận 3D thành Vector 1D, đưa qua lớp Dense và hàm Softmax để tính xác suất phân loại:

Xác suất Softmax: $\hat{y}_i = e^{z_i} / \sum_j e^{z_j}$

Hàm Mất mát Cross-Entropy: $L(y, \hat{y}) = - \sum_i y_i \log(\hat{y}_i)$

5. Bảng So sánh Tham số & Mở rộng Tác vụ Thị giác Máy tính

CNN không chỉ dùng cho Phân loại Ảnh (Classification) mà còn là nền tảng cho nhiều bài toán thị giác phức tạp:

Tác vụ (Task)	Mô tả / Đầu ra (Description & Output)	Ứng dụng Thực tế (Applications)
Image Classification	Dự đoán 1 nhãn danh mục duy nhất cho toàn bộ bức ảnh.	Nhận diện chữ số MNIST, phân loại bệnh qua ảnh X-quang.
Object Detection	Dự đoán tọa độ Bounding Box (x, y, w, h) + Nhãn cho nhiều đối tượng.	Xe tự lái (YOLO), giám sát an ninh, đếm phương tiện.
Semantic Segmentation	Phân loại từng điểm ảnh (Pixel-level Classification).	Phân tách khối u y tế (U-Net), bản đồ vệ tinh.
Instance Segmentation	Phân loại từng điểm ảnh và phân biệt từng thể hiện đối tượng riêng biệt.	Chỉnh sửa ảnh tự động, robot gấp sản phẩm.

TÓM TẮT BỘ QUY TẮC THIẾT KẾ MẠNG CNN:

- Spatial Size Reduction:** Kích thước không gian (W, H) giảm dần qua các lớp Max Pooling.
- Channel Expansion:** Số lượng kênh đặc trưng (C_{out}) tăng dần qua các lớp Cuộn để học đặc trưng trừu tượng.
- Weight Efficiency:** Chia sẻ trọng số giúp CNN tiết kiệm hàng triệu tham số so với mạng Dense thông thường.